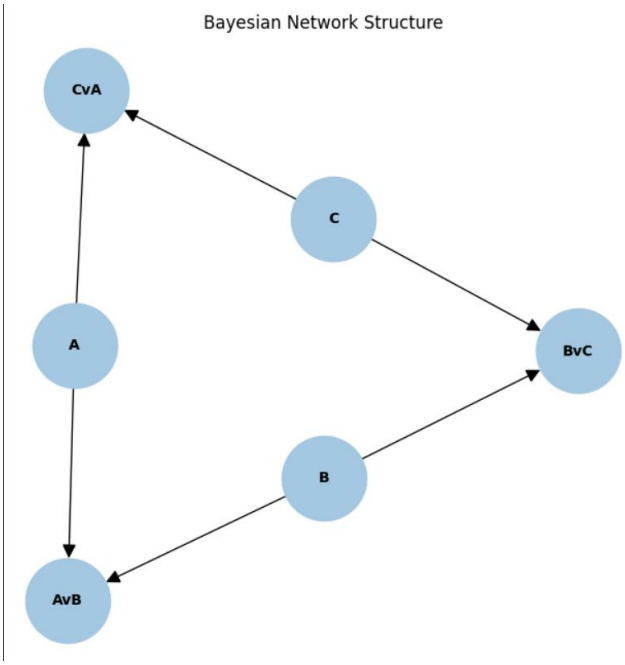
دانشگاه صنعتی امیرکبیر
(پلی تکنیک تهران)

کیانا شرافتی ۴۰۱۳۱۰۲۲

پروژه ۴ مبانی هوش مصنوعی

تعریف شبکه بیزی و ساختار گراف

در این پروژه ابتدا شبکه‌های بیزی مطابق با ساختار علّی مسئله طراحی شدند. سپس جداول احتمال شرطی بر اساس منطق مسئله مقداردهی گردید. پس از آن، روش‌های استنتاج دقیق و تقریبی پیاده‌سازی و روی کوئری‌های یکسان اجرا شدند. در نهایت، نتایج به‌صورت عددی و تحلیلی با یکدیگر مقایسه شدند تا رفتار و کارایی هر روش بررسی شود.



شکل ۱- ساختار شبکه بیزی طراحی‌شده که روابط علّی بین متغیرهای اصلی سیستم را نشان می‌دهد

در این پروژه دو شبکه‌ی بیزی تعریف شد:

۱. شبکه‌ی نیروگاه هسته‌ای(Alarm–Gauge–Faults–Temperature)

۲. شبکه‌ی مسابقات تیم‌ها(Skills–Match Outcomes)

الف) شبکه‌ی نیروگاه هسته‌ای

گره‌ها

- **T**: دمای واقعی(Hot/Normal)
- **F_G**: خرابی گیج(Faulty/Not Faulty)
- **G**: خوانش گیج(Hot/Normal)

- **F_A**: خرابی آلارم(Faulty/Not Faulty)
- **A**: صدای آلارم(On/Off)

ساختار گراف (روابط والد-فرزند)

- $T \rightarrow F_G$
- $T \rightarrow G$
- $F_G \rightarrow G$
- $G \rightarrow A$
- $F_A \rightarrow A$

۱-ساختار انتخاب‌شده چگونه روابط علت و معلولی مسئله واقعی را منعکس می‌کند؟

این شبکه دقیقاً مطابق زنجیره‌ی علّی سیستم واقعی ساخته شده است:

- دمای واقعی (T) علت اصلی رخدادهای فیزیکی سیستم است. افزایش دما هم احتمال خرابی گیج را بالا می‌برد و هم مقدار واقعی‌ای است که گیج باید اندازه‌گیری کند. بنابراین یال‌های $T \rightarrow F_G$ و $T \rightarrow G$ بیانگر این واقعیت‌اند که «شرایط فیزیکی» هم بر عملکرد ابزار و هم بر مقدار مشاهده‌شده اثر می‌گذارد.
- خوانش گیج (G) یک «مشاهده‌ی نویزی» از دمای واقعی است و کیفیت آن به خرابی گیج (F_G) وابسته است. بنابراین $F_G \rightarrow G$ بازتاب می‌دهد که خطای مشاهده از کیفیت ابزار ناشی می‌شود.
- آلارم (A) یک واکنش کنترلی به خوانش گیج (G) است، اما این واکنش می‌تواند تحت تأثیر خرابی آلارم (F_A) قرار گیرد. بنابراین یال‌های $G \rightarrow A$ و $F_A \rightarrow A$ دقیقاً مدل می‌کنند که آلارم هم به ورودی‌اش وابسته است و هم ممکن است خودش خراب باشد.

در یک جمله: این گراف به‌درستی زنجیره‌ی «علت فیزیکی ← ابزار اندازه‌گیری ← تصمیم/هشدار» و هم‌زمان اثر «خرابی اجزا» را مدل کرده است.

۲- اگر یک یال جدید اضافه یا حذف می‌شد، چه تغییری در تفسیر مدل ایجاد می‌شد؟

نمونه‌های مهم:

- **اگر یال G → T حذف شود**:

مدل ادعا می‌کند خوانش گیج هیچ وابستگی مستقیمی به دمای واقعی ندارد و فقط به خرابی گیج وابسته است؛ این تفسیر کاملاً غلط است، چون حتی گیج سالم هم باید به دما وابسته باشد.

- **اگر یال F_A → A حذف شود**:

مدل فرض می‌کند خرابی آلارم هیچ اثری روی خروجی آلارم ندارد. در این صورت، مفهوم «faulty alarm»بی‌معنی می‌شود و احتمال‌های شرطی داده‌شده در صورت مسئله دیگر قابل مدل‌سازی نیستند.

- **اگر یال مستقیم T → A اضافه شود**:

مدل می‌گوید آلارم علاوه بر گیج، «به‌طور مستقیم» از دمای واقعی هم اثر می‌گیرد (مثل داشتن سنسور دوم یا دستیابی مستقیم به دما). این باعث می‌شود آلارم حتی وقتی گیج خطا دارد، با دمای واقعی همبستگی اضافی پیدا کند؛ این تغییر، سیستم واقعی مسئله را تغییر می‌دهد و باید فقط وقتی پذیرفته شود که واقعاً آلارم یک مسیر مستقل برای دریافت دما داشته باشد.

ب) شبکه‌ی مسابقات تیم‌ها (۳ تیم و تعمیم به ۵ تیم)

گره‌ها در نسخه ۳ تیمی

- **A, B, C**: سطح مهارت هر تیم (۰ تا ۳)
- **AvB, BvC, CvA**: نتیجه بازی‌ها (۰=تیم اول می‌برد، ۱=تیم دوم می‌برد، ۲=مساوی)

ساختار گراف

- A → AvB, B → AvB
- B → BvC, C → BvC
- C → CvA, A → CvA

در نسخه ۵ تیمی همین الگو به صورت چرخه‌ای برای T1..T5 و ۵ بازی اعمال می‌شود.

۱- ساختار انتخاب‌شده چگونه روابط علت و معلولی مسئله واقعی را منعکس می‌کند؟

در این مسئله، علت واقعی نتیجه‌ی هر مسابقه «مهارت دو تیم شرکت‌کننده» است. بنابراین:

- مهارت تیم‌ها (A, B, C) به‌عنوان متغیرهای بنیادی و مستقل مدل شدند (ریشه‌های گراف). این یعنی قبل از مشاهده‌ی مسابقات، مهارت‌ها با یک prior ثابت شروع می‌شوند.
- نتیجه‌ی هر بازی فقط به دو مهارت مربوطه وابسته است.
مثلاً نتیجه‌ی AvB تنها از A و B اثر می‌گیرد. این دقیقاً همان فرض مسئله است که «Outcome به اختلاف مهارت‌ها وابسته است» و هیچ عامل پنهان دیگری در مدل لحاظ نشده است.

به این ترتیب، گراف بیان می‌کند که:

- مهارت‌ها علت هستند
- نتایج مسابقات معلول
- و شواهد (نتایج بازی‌های دیده‌شده) پسین مهارت‌ها را اصلاح می‌کنند و به‌صورت غیرمستقیم پیش‌بینی بازی‌های دیگر را تغییر می‌دهند.

۲- اگر یک یال جدید اضافه یا حذف می‌شد، چه تغییری در تفسیر مدل ایجاد می‌شد؟

- **اگر یکی از یال‌های مهارت به نتیجه حذف شود (مثلاً حذفAvB → B) :**
مدل ادعا می‌کند نتیجه‌ی بازی A و B فقط به مهارت A بستگی دارد و مهارت B بی‌اثر است. این با تعریف مسئله تناقض دارد، چون outcome باید تابع اختلاف مهارت‌ها باشد.
- **اگر یال بین نتایج مسابقات اضافه شود (مثلاً AvB → BvC) :**
این یعنی نتیجه‌ی یک بازی «مستقیماً» نتیجه‌ی بازی بعدی را تعیین می‌کند، مستقل از مهارت‌ها. چنین تفسیری به معنای وجود اثر روانی/فیزیکی مثل خستگی، روحیه، یا مصدومیت انتقالی است. چون مسئله چنین اثری را تعریف نکرده، افزودن این یال مدل را از مسئله اصلی منحرف می‌کند.
- **اگر یال بین مهارت تیم‌ها اضافه شود(مثلاًA → B)**
این یعنی مهارت تیم‌ها مستقل نیست و مهارت یک تیم علت مهارت تیم دیگر است (مثلاً تیم‌ها از هم یاد می‌گیرند یا عضو مشترک دارند). این هم ساختار مسئله را تغییر می‌دهد و فقط در صورت وجود چنین فرضی باید افزوده شود.

مقداردهی و ساخت جداول احتمال شرطی(CPT)

در این پروژه، جداول احتمال شرطی (CPT) هر گره بر اساس منطق مسئله و روابط علّی تعریف‌شده در ساختار گراف تعیین شدند. هدف از مقداردهیCPT ها، مدل‌سازی رفتار واقعی سیستم با در نظر گرفتن عدم قطعیت و نویز در مشاهدات و تصمیم‌گیری‌ها بود. در ادامه، اثر تغییر مقادیر CPT و نقش آن‌ها در رفتار کلی مدل بررسی می‌شود.

CPT: AvB | Parents: A, B

	A=0, B=0	A=0, B=1	A=0, B=2	A=0, B=3	A=1, B=0	A=1, B=1	A=1, B=2	A=1, B=3	A=2, B=0	A=2, B=1	A=2, B=2	A=2, B=3	A=3, B=0	A=3, B=1	A=3, B=2	A=3, B=3
AvB=0	0.1	0.2	0.15	0.05	0.2	0.1	0.2	0.15	0.15	0.2	0.1	0.2	0.05	0.15	0.2	0.1
AvB=1	0.1	0.6	0.75	0.9	0.6	0.1	0.6	0.75	0.75	0.6	0.1	0.6	0.9	0.75	0.6	0.1
AvB=2	0.8	0.2	0.1	0.05	0.2	0.8	0.2	0.1	0.1	0.2	0.8	0.2	0.05	0.1	0.2	0.8

CPT: A | Parents: G, F_A

	G=0, F_A=0	G=0, F_A=1	G=1, F_A=0	G=1, F_A=1
A=0	0.9	0.55	0.1	0.45
A=1	0.1	0.45	0.9	0.55

شکل ۲ – نمونه‌ای از جدول احتمال شرطی که نشان می‌دهد چگونه عدم قطعیت و نویز در رفتار سیستم مدل‌سازی شده

۱- اگر یک مقدار در CPT تغییر کند، کدام روابط در شبکه بیشترین حساسیت را خواهند داشت؟

به‌طور کلی، CPTهایی که در نزدیکی خروجی‌ها یا گره‌های مشاهده‌پذیر قرار دارند، بیشترین حساسیت را دارند؛ زیرا تغییر در آن‌ها مستقیماً روی احتمالات پسین و نتایج استنتاج اثر می‌گذارد.

در شبکه نیروگاه هسته‌ای:

- CPTمربوط به آلارم (A | G, F_A) بیشترین حساسیت را دارد.

  حتی تغییر کوچک در احتمال «واکنش صحیح آلارم» باعث تغییر قابل‌توجه در:

  - احتمال نهایی روشن شدن آلارم

- و استنتاج دمای واقعی می‌شود.
  دلیل آن این است که آلارم یک گره خروجی و مشاهده‌پذیر است و بسیاری از کوئری‌ها مستقیماً به آن شرط می‌شوند.

- CPTخوانش گیج (G | T, F_G) نیز حساس است، زیرا گیج نقش واسط بین دمای واقعی و آلارم را دارد. هر تغییری در دقت گیج مستقیماً به‌صورت تقویت‌شده به آلارم منتقل می‌شود.

در شبکه مسابقات تیم‌ها:

- CPTمربوط به نتایج مسابقات (Match | Skill_i, Skill_j) بیشترین حساسیت را دارد.
  تغییر در احتمالات برد/باخت/مساوی برای اختلاف مهارت‌ها باعث می‌شود:
  - شواهد (نتایج بازی‌ها) قدرت متفاوتی در اصلاح مهارت تیم‌ها داشته باشند
  - پیش‌بینی بازی‌های آینده به‌طور قابل‌توجه تغییر کند

در مقابل، CPTهای prior مهارت تیم‌ها حساسیت کمتری دارند، زیرا با مشاهده‌ی چند نتیجه مسابقه به‌سرعت توسط داده‌ها اصلاح می‌شوند.

۲- کدام CPT بیشترین نقش را در تعیین رفتار کلی مدل ایفا می‌کند؟

در شبکه نیروگاه هسته‌ای:
مهم‌ترینCPT ، جدول $P(A|G,F_A)$ است.

این CPT تعیین می‌کند:

- آیا آلارم یک نشانگر قابل‌اعتماد برای وضعیت سیستم است یا خیر
- چه میزان می‌توان از مشاهده‌ی آلارم برای استنتاج دمای واقعی استفاده کرد

اگر آلارم حتی در حالت سالم واکنش ضعیفی داشته باشد، کل مدل هشداردهی عملاً بی‌اثر می‌شود.
بنابراین این CPT نقش «نقطه‌ی تصمیم‌گیری نهایی» را در سیستم ایفا می‌کند.

در شبکه مسابقات تیم‌ها:
CPT مربوط به احتمال نتیجه مسابقه بر اساس اختلاف مهارت‌ها مهم‌ترین بخش مدل است.
این جدول مشخص می‌کند که:

- شواهد چقدر قوی هستند
- آیا برد یک تیم واقعاً اطلاعات زیادی درباره‌ی مهارت‌ها می‌دهد یا خیر

به بیان دیگر، این CPT تعیین می‌کند که «نتیجه‌ی یک بازی چقدر آموزنده است». اگر این جدول به‌گونه‌ای تنظیم شود که حتی اختلاف مهارت زیاد هم اغلب به مساوی منجر شود، کل مدل قدرت پیش‌بینی خود را از دست می‌دهد.

۳- آیا جایی در شبکه مشاهده شد که وابستگی شرطی موجب سادگی یا پیچیدگی مدل شود؟ مثال بزنید.

بله، وابستگی‌های شرطی نقش کلیدی در سادگی محاسباتی و مفهومی مدل داشته‌اند.

مثال از سادگی(Conditional Independence) :

- در شبکه مسابقات، فرض استقلال شرطی زیر اعمال شده است:

نتایج مسابقات، با دانستن مهارت تیم‌ها، مستقل از یکدیگر هستند.

این فرض باعث می‌شود:

- هر CPT فقط به دو مهارت وابسته باشد
- فضای حالت و پیچیدگی محاسباتی به‌شدت کاهش یابد
- روش‌های Sampling مانند Gibbs به‌صورت کارآمد اجرا شوند

اگر نتایج مسابقات به یکدیگر وابسته در نظر گرفته می‌شدند (مثلاً اثر خستگی یا روحیه)، مدل به‌مراتب پیچیده‌تر و سنگین‌تر می‌شد.

مثال از افزایش پیچیدگی:

- در شبکه نیروگاه، گره Gبه دو والد Tو F_Gوابسته است.
  این وابستگی شرطی باعث می‌شود CPT دو بعدی تعریف شود و محاسبات نسبت به یک مشاهده‌ی ساده پیچیده‌تر گردد، اما این پیچیدگی ضروری و واقعی است؛ زیرا کیفیت مشاهده هم به وضعیت سیستم و هم به خرابی ابزار بستگی دارد.

بنابراین در این پروژه، وابستگی‌های شرطی به‌گونه‌ای انتخاب شده‌اند که:

- در جایی که امکان سادگی وجود دارد (مانند استقلال نتایج با شرط مهارت‌ها)، مدل ساده شود
- و در جایی که واقعیت سیستم ایجاب می‌کند، پیچیدگی حفظ شود

نمودار ساختار شبکه و جداولCPT

۱- در شبکه شما کدام گره «متمرکزتر» است و این چه معنایی در تحلیل مسئله دارد؟

در شبکه نیروگاه هسته‌ای، گره آلارم (A) متمرکزترین گره شبکه است.

این گره دارای چند والد (خوانش گیج G و وضعیت خرابی آلارم F_A بوده و در عین حال، به‌عنوان گره خروجی و مشاهده‌پذیر سیستم عمل می‌کند. متمرکز بودن این گره به این معناست که:

- چندین عامل مستقل (وضعیت واقعی سیستم و خرابی تجهیزات) به‌صورت هم‌زمان بر آن اثر می‌گذارند.
- این گره نقطه‌ی نهایی تجمیع اطلاعات در شبکه است.
- بیشتر پرس‌وجوهای استنتاجی (Inference) به‌طور مستقیم یا غیرمستقیم به این گره وابسته هستند.

در تحلیل مسئله، این تمرکز نشان می‌دهد که آلارم نقش تصمیم‌ساز اصلی را دارد و کیفیت مدل‌سازی آن تأثیر مستقیم بر قابلیت اعتماد سیستم هشداردهی خواهد داشت.

در شبکه مسابقات تیم‌ها نیز، گره‌های مربوط به نتایج مسابقات (مانند AvB، BvC) گره‌های متمرکز محسوب می‌شوند، زیرا هرکدام از آن‌ها به دو گره مهارت تیم‌ها وابسته هستند و نقش اصلی را در انتقال اطلاعات از مهارت‌های پنهان به شواهد قابل مشاهده ایفا می‌کنند.

۲- اگر بخواهید شبکه را برای داده‌های واقعی گسترش دهید، تغییرات ساختاری از کجا آغاز می‌شود؟

برای گسترش شبکه به داده‌های واقعی‌تر، تغییرات ساختاری ابتدا از لایه‌ی علّی و متغیرهای پنهان آغاز می‌شود، نه از گره‌های خروجی.

به‌طور مشخص:

- در شبکه نیروگاه هسته‌ای، می‌توان گره‌های جدیدی مانند:
  - شدت دما (چندسطحی به‌جای دودویی)
  - انواع مختلف خرابی تجهیزات
  - شرایط محیطی یا خطای انسانی

  را به‌عنوان والدهای جدید به شبکه اضافه کرد. این تغییرات ابتدا در گره‌های علت (مانند

دما یا خرابی‌ها) اعمال می‌شوند و سپس اثر آن‌ها به‌صورت طبیعی به گره‌های مشاهده‌پذیر منتقل می‌شود.

- در شبکه مسابقات تیم‌ها، گسترش ساختار می‌تواند از:
  - افزودن گره‌هایی مانند فرم تیم، میزبان بودن، یا خستگی
  - یا مدل‌سازی وابستگی زمانی بین مسابقات متوالی آغاز شود. این تغییرات معمولاً در سطح مهارت یا شرایط بازی اعمال می‌شوند و سپس بر CPT نتایج مسابقات اثر می‌گذارند.

به‌طور کلی، گسترش شبکه برای داده‌های واقعی با غنی‌تر کردن علل پنهان و حفظ ساختار منطقی روابط انجام می‌شود تا بدون از بین رفتن قابلیت استنتاج، دقت مدل افزایش یابد.

استنتاج در شبکه بیزی(Exact & Approximate Inference)

الف) استنتاج دقیق(Exact Inference)

در این بخش، دو روش شمارش کامل (Enumeration) و حذف متغیر (Variable Elimination) پیاده‌سازی و مقایسه شدند.

۱- چرا پیچیدگی زمانی Enumeration از نظر تئوری بالا است؟ این موضوع در شبکه شما چگونه مشاهده می‌شود؟

روش Enumeration برای محاسبه‌ی یک کوئری، مجبور است تمام حالت‌های ممکن متغیرهای پنهان را بررسی کرده و روی آن‌ها جمع بزند. اگر تعداد متغیرها n و هر متغیر دودویی باشد، تعداد حالات برابر با 2^n خواهد بود. بنابراین پیچیدگی زمانی این روش به‌صورت نمایی با اندازه شبکه رشد می‌کند.

در شبکه‌های پیاده‌سازی‌شده در این پروژه:

- در شبکه نیروگاه، افزایش تعداد متغیرهای پنهان باعث افزایش محسوس زمان محاسبه شد.
- در شبکه مسابقات تیم‌ها، به‌ویژه با افزایش تعداد تیم‌ها، Enumeration به‌سرعت غیرعملی می‌شود، زیرا باید تمام ترکیبات ممکن مهارت‌ها و نتایج مسابقات را بررسی کند.

این رفتار نشان می‌دهد که Enumeration از نظر تئوری ساده اما از نظر محاسباتی بسیار پرهزینه است.

۲-حذف متغیر چگونه فضای محاسباتی را کاهش می‌دهد؟ مثال بزنید.

روش حذف متغیر با بازآرایی محاسبات، از انجام محاسبات تکراری جلوگیری می‌کند. به‌جای محاسبه‌ی کل توزیع مشترک، این روش:

- ابتدا عوامل (Factors) مرتبط با یک متغیر را ترکیب می‌کند
- سپس آن متغیر را با عمل جمع‌زدن حذف می‌کند

در شبکه نیروگاه، هنگام حذف متغیرهایی مانند وضعیت خرابی یا خوانش گیج، به‌جای بررسی تمام حالت‌های ممکن، فقط عوامل محلی مرتبط ترکیب شدند. این کار باعث شد فضای حالت به‌شدت کاهش یابد.

در مقایسه با Enumeration، این روش محاسبات بسیار کمتری انجام می‌دهد، در حالی که نتیجه‌ی دقیق یکسانی تولید می‌کند.

۳- ترتیب حذف متغیرها چه تأثیری بر سرعت اجرای الگوریتم دارد؟

ترتیب حذف متغیرها تأثیر مستقیم بر اندازه‌ی عوامل میانی دارد. اگر متغیری حذف شود که به تعداد زیادی از متغیرهای دیگر وابسته است، عامل حاصل بزرگ و محاسبات سنگین می‌شود.

در مقابل، حذف متغیرهایی با وابستگی کمتر در مراحل اولیه:

- اندازه‌ی عوامل را کوچک نگه می‌دارد
- باعث کاهش زمان اجرا می‌شود

در پیاده‌سازی این پروژه مشاهده شد که ترتیب حذف نامناسب می‌تواند زمان اجرای Variable Elimination را به‌طور قابل‌توجهی افزایش دهد، حتی با وجود اینکه الگوریتم از نظر تئوری بهینه‌تر از Enumeration است.

ب) استنتاج تقریبی(Approximate Inference)

در این بخش، سه روش Rejection Sampling، Likelihood Weighting و Gibbs Sampling پیاده‌سازی و با یکدیگر و با روش‌های دقیق مقایسه شدند.

۱-چرا Rejection Sampling در شبکه‌های با شواهد کم‌احتمال عملکرد ضعیفی دارد؟ آیا این موضوع در مدل شما دیده شد؟

در Rejection Sampling ، نمونه‌هایی که با شواهد ناسازگار باشند کاملاً کنار گذاشته می‌شوند. اگر شواهد احتمال کمی داشته باشند، بخش زیادی از نمونه‌ها رد می‌شوند و تعداد نمونه‌های مؤثر بسیار کاهش می‌یابد.

در شبکه مسابقات ۵ تیمی، با افزایش تعداد شواهد (۴ نتیجه‌ی مشخص مسابقه)، نرخ پذیرش نمونه‌ها کاهش یافت و برای رسیدن به تخمین پایدار نیاز به تعداد نمونه‌های بسیار بیشتری بود. این رفتار دقیقاً نشان‌دهنده‌ی ضعف ذاتی Rejection Sampling در چنین شرایطی است.

۲- Likelihood Weighting چگونه مشکل Rejection را کاهش می‌دهد؟ وزن‌ها چه نقشی دارند؟

Likelihood Weighting به‌جای حذف نمونه‌ها، همه‌ی نمونه‌ها را نگه می‌دارد اما به آن‌ها وزن اختصاص می‌دهد. وزن هر نمونه برابر با احتمال شواهد داده‌شده، مشروط بر مقادیر نمونه‌شده است.

در این پروژه:

- هیچ نمونه‌ای حذف نشد
- نمونه‌هایی که با شواهد سازگارتر بودند وزن بیشتری گرفتند
- همگرایی سریع‌تر و پایدارتر نسبت به Rejection Sampling مشاهده شد

وزن‌ها نقش کلیدی در هدایت تخمین نهایی به سمت مقادیر محتمل‌تر ایفا می‌کنند.

۳- Gibbs Sampling چه فرضی درباره ساختار شبکه دارد؟ آیا این روش روی شبکه شما سریع همگرا شد؟

Gibbs Sampling فرض می‌کند که:

- می‌توان هر متغیر را تنها با دانستن پوشش مارکوف (Markov Blanket) آن نمونه‌برداری کرد.
- شبکه اتصال‌پذیر بوده و امکان حرکت تدریجی بین حالات وجود دارد.

در شبکه مسابقات تیم‌ها، به دلیل وابستگی‌های محلی و ساختار نسبتاً ساده، Gibbs Sampling سریع همگرا شد و نوسان کمتری نسبت به Rejection Sampling نشان داد. نتایج آن نیز به Likelihood Weightingبسیار نزدیک بود.

۴- دقت خروجی‌ها را بین سه روش مقایسه کنید. کدام یک پایدارتر بود؟

بر اساس نتایج عددی:

- Rejection Sampling بیشترین نوسان را داشت
- Likelihood Weighting نتایج پایدارتر و نزدیک‌تری به مقدار دقیق ارائه داد
- Gibbs Sampling پایدارترین نتایج را با کمترین نوسان نشان داد، به‌ویژه در تعداد نمونه‌های بالا

در مجموع، Gibbs Sampling و Likelihood Weighting از نظر دقت و پایداری عملکرد بهتری نسبت به Rejection Sampling داشتند.

```
3-TEAM Comparison (Query=CvA | Evidence: AvB=0, BvC=2)
Outcome meanings for CvA: 0=C wins, 1=A wins, 2=tie

Exact (Enumeration):      [0.16141938297176492, 0.48171263490679167, 0.3568679821214434]
Rejection Sampling:       [0.24184829991281603, 0.4591107236268527, 0.2990409764603313]   | L1=0.1609
Likelihood Weighting:     [0.2482874882610933, 0.4556297656041826, 0.2960827461347241]   | L1=0.1737
Gibbs Sampling:           [0.24672, 0.45822, 0.29506]   | L1=0.1706
```

شکل ۳- همان‌طور که مشاهده می‌شود، روش‌های تقریبی با افزایش تعداد نمونه‌ها به نتایج استنتاج دقیق نزدیک می‌شوند، اما سرعت همگرایی و پایداری آن‌ها متفاوت است.